Protokol Pencarian Data Kuantitatif Kritis untuk Pemodelan Volatilitas Tinggi PT GoTo Gojek Tokopedia Tbk (GOTO): Justifikasi Empiris dan Metodologis Kesenjangan Penelitian dalam Ekonometrika Deret Waktu Finansial

I. Pendahuluan dan Konteks Masalah Finansial

1.1. Latar Belakang Volatilitas Saham GOTO dalam Pasar Modal Indonesia

PT GoTo Gojek Tokopedia Tbk (GOTO) merupakan emiten teknologi dengan ekosistem digital terbesar di Indonesia, yang pergerakan harga sahamnya menjadi subjek analisis kritis karena tingkat fluktuasi yang ekstrem sejak pencatatan saham perdana (*Initial Public Offering* – IPO). Saham GOTO telah menjadi pusat perhatian investor, khususnya Generasi Z, yang merupakan kelompok yang semakin dominan dalam partisipasi pasar modal Indonesia.[1] Meskipun demikian, saham GOTO menampilkan dinamika harga yang sangat agresif.
Data historis menunjukkan bahwa harga IPO GOTO sempat berada di level Rp 338 per saham. Namun, dalam periode waktu yang relatif singkat, saham tersebut mengalami koreksi masif hingga anjlok ke level Rp 86 per saham pada Desember 2023.[1] Penurunan harga yang mendekati 75% dari harga IPO ini menempatkan GOTO sebagai studi kasus risiko ekor (*tail risk*) yang ekstrem dalam konteks pasar modal Indonesia. Volatilitas tinggi ini bukan sekadar fluktuasi harga harian yang normal, melainkan sebuah perubahan struktural yang dipengaruhi oleh faktor likuiditas, sentimen pasar, dan aksi korporasi. Sebagai contoh, pada April 2023, saham GOTO sempat menyentuh *auto reject bawah* (ARB) pada harga Rp 97 per saham, dengan nilai transaksi harian mencapai Rp 319,67 miliar dan kapitalisasi pasar yang terus menurun hingga Rp 111,33 triliun.[2] Fenomena ini menggarisbawahi perlunya metode prediksi yang mampu mengelola non-stasioneritas dan probabilitas kejadian ekstrem.

1.2. Justifikasi Kebutuhan Analisis Prediktif Akurat di Lingkungan Volatil

Tingkat volatilitas yang masif ini menimbulkan tantangan serius bagi investor, terutama investor pemula, yang rentan terhadap kerugian akibat pengambilan keputusan investasi yang didasarkan pada informasi terbatas.[1] Kebutuhan akan prediksi harga saham yang akurat semakin mendesak untuk memitigasi risiko kerugian modal (capital loss).[1]
Dalam konteks GOTO, kompleksitas prediksinya diperparah oleh transisi kinerja fundamental perusahaan. Laporan keuangan GOTO mulai menunjukkan perbaikan signifikan, seperti pencapaian *Group Adjusted EBITDA* positif sebesar Rp 137 miliar pada Kuartal III 2024, didorong oleh pertumbuhan *Group Core GTV* sebesar 74% secara *Year-over-Year* (YoY).[3]
Model prediksi yang dirancang harus mampu membedakan sinyal harga yang didorong oleh perbaikan fundamental ini (yang cenderung bersifat jangka panjang) dari *noise* pasar atau sentimen jangka pendek yang memicu volatilitas ekstrem. Oleh karena itu, diperlukan protokol pengumpulan data yang tidak hanya mencakup data harga historis (teknikal) tetapi juga metrik kinerja operasional dan finansial (fundamental) untuk mendukung pemodelan multivariat.

II. Landasan Teoritis dan Tinjauan Kritis Literatur

2.1. Definisi Kuantitatif Volatilitas Saham dan Tantangan Pemodelan Deret Waktu

Secara kuantitatif, volatilitas saham didefinisikan sebagai rentang fluktuasi dari data saham.[1] Metrik kunci yang digunakan dalam ekonometrika finansial untuk mengukur fluktuasi harga adalah **Log Return Harian** (R_{t}) dan **Standar Deviasi** (σ) yang mencerminkan risiko. Log Return saham pada saat t dihitung menggunakan rumus:
$$R_{t} = \ln\left(\frac{P_{t}}{P_{t-1}}\right)$$
di mana P_{t} adalah harga saham pada saat t.[1] Volatilitas, σ, selanjutnya diturunkan dari standar deviasi *return* (s) sebagai berikut: $\sigma = s/\sqrt{t}$.[1]
Model tradisional dalam prediksi harga saham, seperti *Geometric Brownian Motion* (GBM), sangat bergantung pada asumsi bahwa nilai *return* saham berdistribusi normal.[1] Namun, saham dengan volatilitas sangat tinggi seperti GOTO sering melanggar asumsi normalitas ini. Ketika asumsi distribusi normal dilanggar, model stokastik klasik cenderung menghasilkan *error* prediksi yang besar, terutama dalam jangka waktu yang panjang.[1] Misalnya, dalam sebuah studi yang menggunakan GBM untuk memprediksi harga GOTO, nilai *Mean Absolute*

Percentage Error (MAPE) yang dihasilkan adalah 8,09%, bahkan setelah 1000 iterasi. Akibatnya, GBM perlu dimodifikasi dengan metode *filtering* seperti Kalman Filter (GBM-KF) untuk mencapai MAPE yang jauh lebih kecil, yaitu 2,56%.[1] Kebutuhan untuk memodifikasi model klasik ini memperkuat argumen bahwa data GOTO bersifat kompleks dan tidak dapat dimodelkan secara memadai dengan pendekatan regresi linier atau stokastik dasar.

2.2. Perbandingan Kinerja Model Prediksi dalam Mengelola Non-Linearitas

Untuk mengatasi tantangan non-linearitas dan ketergantungan temporal yang ditimbulkan oleh volatilitas tinggi, tinjauan literatur mengarahkan pada dua kelas model prediksi yang lebih canggih: *Deep Learning* dan *Ensemble Learning*.

Deep Learning (Long Short-Term Memory / LSTM)

LSTM merupakan evolusi dari *Recurrent Neural Network* (RNN) yang dirancang khusus untuk memproses data berurutan (*time series*) dan mengatasi masalah *vanishing gradient* yang menghambat RNN standar dalam menangkap *dependensi jangka panjang*.[1] Dalam konteks data finansial yang fluktuatif, seperti harga saham [1] atau *cryptocurrency* [1], LSTM terbukti mampu memberikan prediksi yang lebih akurat karena mekanisme sel memori dan gerbangnya yang efektif dalam menyimpan informasi penting dari masa lalu.[1] Studi komparatif sering menunjukkan keunggulan LSTM:

- Pada prediksi harga saham Tesla yang sangat fluktuatif, LSTM menghasilkan MAE dan RMSE yang lebih rendah dibandingkan *Extreme Gradient Boosting* (XGBoost).[1]
- Pada data *cryptocurrency* yang volatil, LSTM juga secara konsisten mengungguli *Support Vector Machine* (SVM), *Random Forest*, dan *Regresi Linear* (LR).[1]

Ensemble Modeling (XGBoost dan Hybrid Model)

XGBoost adalah algoritma *ensemble learning* berbasis pohon keputusan yang efisien dalam tugas regresi dan dikenal unggul dalam seleksi fitur.[1] Namun, XGBoost tunggal, meskipun cepat dan akurat untuk prediksi jangka pendek, kurang efektif dalam menangkap dependensi temporal jangka panjang dibandingkan LSTM.[1]
Oleh karena itu, pendekatan yang paling menjanjikan untuk aset super-volatil adalah **Hybrid Model LSTM-XGBoost**. Model hibrida ini menggabungkan kekuatan LSTM dalam mengekstrak fitur temporal dan pola deret waktu non-linear, dengan kemampuan XGBoost dalam memodelkan hubungan kompleks antar fitur dan meminimalkan residu prediksi.[1] Dalam penelitian pada saham *blue chip* seperti BBRI, model Hybrid LSTM-XGBoost berhasil

melampaui model dasarnya, mencapai skor evaluasi MAPE 2,21%, RMSE 117,89, dan MAE 92,45.[1] Keberhasilan ini memberikan justifikasi teoritis yang kuat untuk penerapan model serupa pada GOTO.

III. Analisis Kesenjangan Empiris dan Metodologis GOTO (The Research Gap)

Kesenjangan penelitian yang utama didasarkan pada kontradiksi empiris antara sifat volatil GOTO yang terbukti, dan klaim akurasi luar biasa yang disajikan oleh studi pemodelan yang lebih sederhana. Eksplorasi kesenjangan ini menjadi dasar logis untuk merumuskan urgensi penelitian yang diusulkan.

3.1. Kuantifikasi Fenomena Volatilitas GOTO: Bukti untuk Argumentasi Bab I

Langkah pertama dalam menetapkan kesenjangan adalah secara numerik menunjukkan bahwa GOTO adalah aset dengan risiko abnormal di Pasar Modal Indonesia. Data kuantitatif mengenai pergerakan harga dan perbandingan dengan *benchmark* diperlukan untuk memberikan bukti empiris yang kuat.

Pergerakan harga GOTO menunjukkan koreksi harga ekstrem: dari harga IPO Rp 338/saham, harga saham anjlok ke level terendah Rp 86/saham.[1] Volatilitas ini juga dipicu oleh peristiwa likuiditas seperti berakhirnya masa *lock-up* pada akhir November tahun 2022 dan pelepasan saham oleh pemegang saham awal (misalnya Softbank).[2] Selain itu, volatilitas diperburuk oleh reaksi pasar yang tidak terduga terhadap aksi korporasi besar, seperti anjloknya harga sebesar 20,37% setelah pengumuman kemitraan dengan TikTok pada Desember 2023.[1]

Data yang dikumpulkan harus memfasilitasi perbandingan kuantitatif berikut, yang akan digunakan untuk mengukur risiko GOTO dibandingkan pasar secara umum (IHSG) dan pesaing (*peer group*):

Table 1. Perbandingan Kuantifikasi Volatilitas Saham GOTO vs. Peer Group

Metrik Risiko	**GOTO (Target Data)**	**IHSG (Benchmark)**	**Peer Group (e.g., BUKA)**	**Signifikansi untuk Kesenjangan**
Annualized Volatility (σ, %)				Menunjukkan GOTO adalah *outlier* volatilitas, membenarkan kebutuhan metodologi

				khusus.
Perubahan Harga Ekstrem (IPO ke Low)	Rp 338 $\rightarrow$ Rp 86	N/A	N/A	Bukti empiris koreksi struktural harga yang masif.[1]
Frekuensi ARB/ARA (sejak IPO)				Mengukur tingkat ketidakpastian pasar yang ekstrem.

3.2. Penemuan dan Eksploitasi Kesenjangan Metodologis: Anomali Prediksi GOTO

Kesenjangan metodologis utama terletak pada temuan bahwa model regresi sederhana mengklaim akurasi sempurna dalam memprediksi saham yang sangat volatil. Sebuah studi komparatif menemukan bahwa *Linear Regression* menunjukkan performa terbaik untuk prediksi harga GOTO dengan *Mean Squared Error* (MSE) mendekati nol ($9.82e^{-27}$), RMSE sebesar $9.91e^{-14}$, dan MAE sebesar $8.71e^{-14}$.[1]
Klaim hasil prediksi dengan *error* mendekati nol (10^{-14}) untuk aset yang dikenal sangat volatil seperti GOTO merupakan **anomali statistik** dan tidak realistis dalam pemodelan finansial deret waktu. Dalam data *time series* pasar yang sebenarnya, hasil yang mendekati sempurna seringkali mengindikasikan adanya *data leakage*, pemilihan fitur yang terlalu homogen, atau skema pengujian yang tidak merefleksikan volatilitas pasar, sehingga model gagal dalam melakukan generalisasi prediksi pada data uji yang tidak terlihat.
Sebaliknya, studi yang menggunakan model yang lebih sesuai untuk deret waktu, seperti GBM-KF, pada periode volatil (Okt-Des 2023) menghasilkan MAPE antara 2,56% hingga 8,09%.[1] Adanya selisih yang signifikan antara hasil prediksi model sederhana (klaim e^{-14}) dan model stokastik yang lebih kompleks (MAPE > 2%) mengindikasikan ketidaksesuaian metodologi pada penelitian terdahulu.[1]
Kesenjangan penelitian ini terletak pada perlunya validasi ulang asumsi data GOTO dan pembuktian bahwa hanya model yang secara inheren dirancang untuk menangani non-linearitas dan ketergantungan temporal (yaitu, Deep Learning dan Hybrid Ensemble) yang dapat memberikan prediksi yang valid, stabil, dan memiliki estimasi kesalahan yang realistis (misalnya, MAPE di bawah 2% seperti yang dicapai pada saham *blue chip* lainnya [1]).
Table 2. Kesenjangan Kinerja Model Prediksi pada Saham GOTO (Studi Terdahulu)

Algoritma	**Studi Referensi**	**Metrik Error (RMSE/MAE/MAPE)**	**Hasil (Validasi/Anomali)**	**Arah Kesenjangan Penelitian**
Linear Regression	Agustina & Gustian [1]	RMSE $\approx$ $9.91e^{-14}$	Anomali statistik, menunjukkan	Membutuhkan model yang tahan

			prediksi sempurna yang tidak realistis untuk aset volatil.	terhadap *noise* dan non-linearitas, serta data *look-back* yang lebih panjang.
GBM/GBM-KF	Rasyidah & Maulana [1]	MAPE $\approx$ 2.56% - 8.09%	Error signifikan, membuktikan GBM dasar tidak optimal untuk prediksi jangka panjang GOTO.	Membutuhkan metodologi yang mengintegrasikan fitur temporal dan *ensemble learning* (misalnya LSTM-XGBoost).
Hybrid LSTM-XGBoost	Penelitian ini (Target)		Menetapkan *baseline* akurasi baru yang valid dan stabil untuk memprediksi harga saham GOTO yang sangat volatil.	Menyajikan model yang lebih kompleks untuk mengatasi non-linearitas dan ketergantungan jangka panjang.

3.3. Perumusan Pertanyaan Penelitian Kuantitatif Berbasis Kesenjangan

Data yang akan dicari dan analisis yang akan dilakukan harus secara eksplisit menjawab pertanyaan kunci yang timbul dari kesenjangan ini:

- "Dapatkah model *Deep Learning* atau *Hybrid Ensemble* (misalnya, Hybrid LSTM-XGBoost) memberikan kinerja prediksi harga saham GOTO yang secara statistik **lebih valid dan stabil** (dengan menguji ketahanan terhadap *tail risk* dan non-linearitas) dibandingkan model regresi sederhana (LR) dan model stokastik (GBM), ketika diuji pada periode volatilitas tinggi pasca-IPO GOTO?"

IV. Protokol Pencarian Data Kuantitatif: Data Primer untuk Pembuktian Kesenjangan

Protokol ini merinci kebutuhan data kuantitatif yang harus dikumpulkan untuk memvalidasi argumen kesenjangan yang berfokus pada volatilitas ekstrem GOTO dan untuk berfungsi sebagai input yang kaya fitur bagi model Deep Learning dan Hybrid Ensemble.

A. Data Historis Harga Saham Harian GOTO

Data ini merupakan fondasi untuk analisis deret waktu, perhitungan volatilitas, dan pemodelan teknikal. Pemilihan periode waktu harus mencakup peristiwa-peristiwa signifikan seperti IPO, berakhirnya *lock-up* saham, dan pengumuman kerjasama besar.

Data yang Dicari	Variabel (Fitur)	Format & Sumber Prioritas	Rentang Waktu Kritis	Justifikasi Kebutuhan
Data Transaksi Harian GOTO	**Open, High, Low, Close** (OHLC), **Adjusted Close**, **Volume**.[1]	*Yahoo Finance/Bloomberg/IDX Historical Data* (Akses API/Web Scraping).	11 April 2022 (IPO) hingga tanggal terbaru (Q4 2024 / Q1 2025).	Data dasar untuk pemodelan *time series* dan kalkulasi *log return*.[1] Fitur *Low* memiliki nilai *importance* tertinggi dalam prediksi harga saham.[1]
Log Return Harian	$R_{t} = \ln(Close_{t} / Close_{t-1})$.[1]	Dihitung dari Data Close Price di atas.	Seluruh periode perdagangan.	Diperlukan untuk Uji Normalitas (Kolmogorov-Smirnov) guna secara empiris menolak asumsi distribusi normal.[1]
Annualized Volatility Harian	σ (Standar Deviasi dari R_t).[1]	Dihitung dari Data Log Return di atas.	Jendela bergulir (misalnya, 30 hari atau 90 hari *rolling standard deviation*).	Kuantifikasi fluktuasi historis GOTO. Parameter ini dapat digunakan sebagai fitur input tambahan dalam model XGBoost.

B. Data Kinerja Finansial dan Operasional (Fundamental) GOTO

Mengingat GOTO masih dalam fase pertumbuhan, mengintegrasikan data fundamental penting untuk membedakan pergerakan harga akibat sentimen jangka pendek dari nilai fundamental yang mendasari. Data ini akan disinkronkan dengan data harga harian untuk

membentuk fitur multi-variat.

Data yang Dicari	Variabel (Fitur)	Format & Sumber Prioritas	Rentang Waktu Kritis	Justifikasi Kebutuhan
Group Gross Transaction Value (GTV)	Nilai Kuartalan.[3]	Laporan Keuangan Kuartalan GOTO (Investor Relations) atau Laporan Analis.	Q2 2022 hingga Q4 2024.	Indikator kinerja operasional dan pertumbuhan ekosistem. Disparitas antara kenaikan GTV dan penurunan harga saham adalah kunci argumen volatilitas.
Gross Revenue	Nilai Kuartalan.[5]	Laporan Keuangan Kuartalan GOTO.	Q2 2022 hingga Q4 2024.	Mengukur pertumbuhan pendapatan grup.
Adjusted EBITDA	Nilai Kuartalan.[3]	Laporan Keuangan Kuartalan GOTO.	Q2 2022 hingga Q4 2024.	Sangat penting untuk melacak transisi perusahaan mencapai profitabilitas (EBITDA positif Q3 2024).[3] Berguna sebagai fitur masukan bagi model regresi.

C. Data Makroekonomi dan Pembanding (External Context)

Data makroekonomi dan pembanding diperlukan untuk menormalisasi data GOTO dari pengaruh pasar yang lebih luas dan menyediakan konteks komparatif industri.

Data yang Dicari	Variabel (Fitur)	Format & Sumber Prioritas	Rentang Waktu Kritis	Justifikasi Kebutuhan
Indeks Harga Saham Gabungan (IHSG)	Harga Penutupan Harian, Volume.	IDX, Yahoo Finance.	11 April 2022 hingga data terbaru.	*Benchmark* pasar untuk analisis risiko sistematis dan perhitungan *Beta* GOTO.

Tingkat Suku Bunga Acuan (BI Rate)	Nilai Bulanan/Rapat Dewan Gubernur.[3]	Bank Indonesia (BI).	Sejak 2022 hingga data terbaru.	Variabel eksternal yang signifikan mempengaruhi pasar saham dan sentimen investor.[1]
Kinerja Peer Global	Harga Penutupan Harian (e.g., Grab, Uber, Amazon).[6]	Yahoo Finance.	Periode yang sama dengan GOTO.	Menyediakan konteks komparatif untuk menilai apakah volatilitas GOTO bersifat unik atau mengikuti tren koreksi pasar teknologi global.

V. Rekomendasi Lanjutan untuk Desain Metodologi Penelitian

Data kuantitatif yang dikumpulkan akan diproses melalui tahapan metodologi yang ketat untuk secara definitif membuktikan kesenjangan dan memvalidasi model yang lebih canggih.

5.1. Uji Normalitas *Return* GOTO untuk Pembenaran Metodologi *Deep Learning*

Setelah data *Log Return* harian GOTO terkumpul, langkah krusial adalah melakukan Uji Normalitas (seperti Kolmogorov-Smirnov atau Jarque-Bera).[1] Hipotesis nol (H_{0}) dalam uji ini adalah bahwa data *return* berdistribusi normal. Model klasik seperti GBM bergantung pada penerimaan H_{0}.[1]
Jika hasil pengujian statistik menunjukkan bahwa H_{0} ditolak (yaitu, data *return* tidak berdistribusi normal), hal ini secara tegas membenarkan bahwa data GOTO melanggar asumsi stasioneritas dan normalitas yang diperlukan oleh model linier dan stokastik dasar. Penolakan ini secara langsung menjadi justifikasi metodologis untuk beralih menggunakan arsitektur *Deep Learning* (seperti LSTM atau GRU) [1] yang dirancang untuk memproses data non-linear dan tidak memerlukan asumsi distribusi.

5.2. Pemilihan Metrik Evaluasi Kinerja yang Rigor

Untuk menghindari anomali statistik seperti *error* mendekati nol yang ditunjukkan oleh regresi sederhana, evaluasi kinerja model harus menggunakan metrik yang sensitif terhadap kesalahan besar dan menyediakan pengukuran relatif.

1. **Mean Absolute Percentage Error (MAPE):** MAPE diukur dalam persentase dari nilai aktual, yang memfasilitasi perbandingan akurasi relatif di berbagai skala harga.[1] Nilai MAPE kurang dari 10% secara umum dikategorikan sebagai "sangat akurat".[1] Penggunaan MAPE sangat penting untuk memvalidasi apakah model Deep Learning dapat mencapai akurasi tinggi yang realistis (misalnya, MAPE di bawah 2% seperti yang dicapai model hibrida pada BBRI [1]), menjauh dari hasil artifisial yang mendekati nol.
2. **Root Mean Squared Error (RMSE):** RMSE adalah metrik yang memberikan bobot lebih besar pada kesalahan prediksi yang besar (outlier) melalui proses pengkuadratan selisih.[1] Mengingat GOTO dikenal karena fluktuasi harga yang ekstrem (*tail risk*), RMSE adalah metrik yang vital untuk mengevaluasi ketahanan model terhadap anomali harga.

5.3. Strategi Pembagian Data (*Time Series Split*) untuk Uji Stabilitas

Untuk memastikan bahwa model memiliki kemampuan generalisasi yang baik dan tidak *overfitting* pada data latih, proses pemisahan data harus dilakukan secara kronologis (Time Series Split), bukan pembagian acak.[1]
Pembagian standar sebesar 80% data latih dan 20% data uji [1] perlu dikombinasikan dengan teknik **Cross-Validation Berbasis Waktu** (misalnya, 5-fold Time Series Split). Pendekatan ini memastikan bahwa model selalu diuji pada data masa depan yang belum pernah dilihat, mereplikasi skenario investasi dunia nyata.[1] Periode pengujian harus mencakup setidaknya rentang waktu 30 hari pasca-pelatihan untuk memvalidasi kinerja prediksi jangka pendek.[1] Proses ini memastikan *robustness* model Deep Learning, yang sangat sensitif terhadap validitas temporal dan *data leakage*.

VI. Kesimpulan dan Arah Penelitian yang Direkomendasikan

Analisis kritis terhadap konteks volatilitas tinggi PT GoTo Gojek Tokopedia Tbk (GOTO) dan tinjauan literatur yang ada mengidentifikasi kesenjangan penelitian yang kuat, baik secara empiris maupun metodologis. Volatilitas ekstrem GOTO, yang terbukti dari penurunan harga masif (dari Rp 338 ke Rp 86) dan seringnya menyentuh ARB [1], memerlukan model prediksi yang lebih canggih daripada model linier atau stokastik klasik.
Protokol pencarian data kuantitatif yang telah dirumuskan—meliputi data teknikal harian (OHLCV, Log Return), data fundamental kuartalan (GTV, Adjusted EBITDA) [3], dan data makroekonomi (IHSG, BI Rate)—bertujuan untuk menyediakan masukan yang kaya fitur. Data ini akan digunakan untuk: (1) secara empiris menguantifikasi volatilitas GOTO dibandingkan

benchmark, dan (2) memvalidasi bahwa asumsi normalitas model tradisional dilanggar (melalui Uji Normalitas pada Log Return).
Untuk mengatasi non-linearitas dan ketergantungan temporal yang ditunjukkan oleh data GOTO, arah penelitian yang direkomendasikan adalah implementasi model **Hybrid LSTM-XGBoost**. Kombinasi arsitektur *gated* LSTM dengan kemampuan *ensemble boosting* XGBoost secara teoritis paling optimal untuk menangkap pola temporal jangka panjang sambil meminimalkan kesalahan prediksi, sehingga dapat menghasilkan estimasi akurasi yang **valid dan stabil** (dengan MAPE dan RMSE yang realistis, bukan mendekati nol) ketika diuji pada periode volatilitas tinggi.

Karya yang dikutip

1. PREDIKSI HARGA SAHAM PT. GOTO GOJEK-TOKOPEDIA MENGGUNAKAN GEOMETRIC BROWNIAN MOTION TERMODIFIKASI KALMAN FILTER DENGAN KONSTRAIN.pdf
2. Ramai-ramai Dilepas Investor, Saham GOTO Sentuh ARB - CNBC Indonesia, diakses November 17, 2025, https://www.cnbcindonesia.com/market/20230410105725-17-428530/ramai-ramai-dilepas-investor-saham-goto-sentuh-arb
3. Group Achieves Positive Adjusted EBITDA as GoTo Announces 2024 Third Quarter Results, diakses November 17, 2025, https://www.gotocompany.com/en/news/press/group-achieves-positive-adjusted-ebitda-as-goto-announces-2024-third-quarter-results
4. Terkoreksi, Ternyata Ini Alasan Harga Saham GoTo Turun - Indo Premier Sekuritas, diakses November 17, 2025, https://www.indopremier.com/ipotnews/newsDetail.php?jdl=Terkoreksi,%20Ternyata%20Ini%20Alasan%20Harga%20Saham%20GoTo%20Turun&news_id=409312&group_news=RESEARCHNEWS&news_date=&taging_subtype=&name=&search=&q=&halaman=
5. GoTo Group Reports Strong Group GTV and Revenue Growth as Company Announces 2024 First Quarter Results, diakses November 17, 2025, https://www.gotocompany.com/en/news/press/goto-group-reports-strong-group-gtv-and-revenue-growth-as-company-announces-2024-first-quarter-results
6. Analis: Koreksi rendah, kepercayaan investor kepada GoTo tetap tinggi - ANTARA News, diakses November 17, 2025, https://www.antaranews.com/berita/2901321/analis-koreksi-rendah-kepercayaan-investor-kepada-goto-tetap-tinggi